

SAMIR EL AISSAOUY

Data Engineer

elaissaouy.samir12@gmail.com | +33752076861 | [LinkedIn](#) | [Github](#) | Ile de france (Mobilité : Libre)

PROFIL

Data Engineer avec plus de 2 ans d'expérience. Spécialisé dans la conception de pipelines de données robustes et la fiabilisation des flux. Maîtrise de l'écosystème Python / PySpark / Databricks et des outils BI (Power BI, Tableau). Habitué à travailler en mode agile au sein d'équipes pluridisciplinaires, avec un souci constant de livrer des solutions claires et exploitables par les utilisateurs finaux.

COMPÉTENCES TECHNIQUES

- **Langages : Python, SQL, R**
- **Big Data : PySpark, Azure Databricks, Delta Lake, Architecture Lakehouse (Bronze/Silver/Gold)**
- **Cloud & Infrastructure : AWS (Lambda, S3, Athena, EC2), Azure (ADLS, Data Factory), Apache Airflow**
- **Bases de Données : ETL/ELT, Architecture Lakehouse (Medallion), Data Quality, PostgreSQL, SQL Server**
- **BI & Dataviz : Power BI, Tableau, Plotly, Matplotlib, Seaborn, Streamlit**
- **Machine Learning : Scikit-Learn, TensorFlow, Keras (séries temporelles, classification, modélisation prédictive)**
- **Outils : Git, Docker, Jira, Azure DevOps, Linux/Bash, Agile/Scrum**
- **Langues : Français (bilingue), Anglais (professionnel)**

FORMATION

Master - Modélisation Mathématique & Analyse Appliquée | [Université Savoie Mont Blanc](#)

2021 – 2023 - Chambéry, France

Master - Mathématiques Pures | [Faculté des Sciences Dhar El-Mahraz](#)

2019 – 2021 - Fès, Maroc

Licence - Mathématiques et Applications | [Faculté des Sciences Dhar El-Mahraz](#)

2016 – 2019 - Fès, Maroc

CERTIFICATIONS

- AWS Certified AI Practitioner AIF-C01 - En cours - Date cible : T2 2026
- Azure Databricks for Data Engineering - Coursera / Microsoft
- Power BI - Formation interne TotalEnergies
- Tableau Desktop - Udemy
- Python & SQL for Data Science - Udemy

EXPÉRIENCE PROFESSIONNELLE

Data Engineer | TotalEnergies - Digital Factory

CDI : Janvier 2023 – Février 2026 - Paris, France

Au sein de la Digital Factory de TotalEnergies, grande direction digitale dédiée à la transformation data du groupe, j'ai contribué à deux projets : NOD (supervision des renouvelables) puis Valbenne (valorisation du biogaz), couvrant l'ensemble de la chaîne data - ingestion, transformation, qualité et restitution - dans un environnement Agile/Scrum.

Ò

Projet 1 - NOD - Supervision des actifs renouvelables

Avec l'accélération des énergies renouvelables chez TotalEnergies, la supervision en temps réel des actifs de production est devenue un enjeu critique. J'ai participé au développement de NOD, la plateforme digitale chargée de centraliser et analyser les données des parcs solaires et éoliens du groupe, pour en améliorer les performances et la sécurité opérationnelle.

- Participation au développement des pipelines de collecte et de traitement des données capteurs IoT (production, irradiance, vitesse du vent, températures) depuis les parcs vers la plateforme Azure Databricks
- Structuration des données en architecture Medallion (Bronze / Silver / Gold) sur Delta Lake, permettant de séparer les flux bruts, les données nettoyées et les agrégats prêts à l'analyse
- Mise en place de l'orchestration des traitements avec Apache Airflow : définition des DAGs, gestion des dépendances entre tâches et alerting automatique en cas d'anomalie ou de dérive de production
- Développement de règles de contrôle qualité sur les flux entrants (détection de valeurs aberrantes, données manquantes, ruptures de séquence) pour garantir la fiabilité des indicateurs de supervision
- Contribution à la création de tableaux de bord Power BI destinés aux équipes opérationnelles pour le suivi des KPIs de performance par site, par technologie et par région

Stack : Python, PySpark, SQL, Azure Databricks, Delta Lake, Apache Airflow, AWS S3, Power BI, Git

Projet 2 - Valbenne - Valorisation de déchets organiques en biogaz

Dans le cadre de la stratégie gaz renouvelables de TotalEnergies, j'ai contribué à l'industrialisation de Valbenne, une plateforme de mise en relation entre producteurs de biomasse et unités de méthanisation pour la production de biogaz.

- Développement et maintenance de pipelines de données sur AWS pour la collecte, transformation et exposition des données de la plateforme (producteurs de biomasse, méthaniseurs, données géospatiales)
- Structuration d'un data lake sur AWS S3 en trois couches (raw / processed / curated) avec contrôles qualité automatisés et alerting sur les anomalies
- Développement de traitements de transformation : nettoyage et standardisation des données de biomasse, enrichissement géospatial (coordonnées GPS, calcul de distances logistiques)
- Collaboration avec les équipes backend pour exposer les données aux microservices et améliorer les algorithmes de matching entre producteurs et méthaniseurs
- Mise en place de tests unitaires et CI/CD via GitHub Actions pour fiabiliser les déploiements en production

Stack : Python, PySpark, SQL, AWS (S3, Lambda, ECS, RDS Aurora, CloudWatch), Airflow, Terraform, GitHub Actions

PROJETS PERSONNELS

Projet 1 - E-Commerce Data Platform - Olist

- Conception et déploiement d'un pipeline de données end-to-end sur 100k commandes réelles (dataset Olist, Brésil 2016–2018), couvrant l'ingestion, la transformation et la validation automatisée
- Architecture Medallion (Bronze / Silver / Gold) avec 12 modèles dbt, orchestrée via Apache Airflow (DAG quotidien, 6 tâches séquentielles)
- Infrastructure complète conteneurisée sous Docker (PostgreSQL, Airflow, Dashboard), migration cloud sur Supabase et 12 checks de qualité des données automatisés
- Dashboard BI interactif déployé sur Streamlit Cloud avec analyse RFM, segmentation clients et suivi des revenus

Stack : Python, SQL, dbt, Airflow, PostgreSQL, Docker, Supabase, Streamlit, GitHub Actions

Projet 2 - Pipeline Lakehouse NYC Taxi - Architecture Medallion

- Conception et déploiement d'un pipeline de données end-to-end traitant plus de 50 millions de trajets, avec transformations Spark distribuées et optimisations de performance (partitionnement, cache, gestion des skews)
- Architecture Medallion (Bronze / Silver / Gold) sur Delta Lake, orchestrée via Apache Airflow avec gestion fine des dépendances et des timeouts
- Infrastructure complète conteneurisée sous Docker (cluster Spark, stockage MinIO/S3, base PostgreSQL) et tests automatisés de qualité des données avec monitoring end-to-end

Stack : Python, SQL, PySpark, Airflow, Delta Lake, MinIO, Docker, PostgreSQL

Projet 3 - Marketing Mix Modeling - Hierarchical Bayesian (Meridian-inspired)

- Conception d'un modèle MMM hiérarchique bayésien multi-géographies inspiré de l'architecture Google Meridian, avec partage de priors entre géos et non-centered parametrization pour une meilleure convergence
- Modélisation complète des effets marketing : adstock géométrique, saturation Hill, et intégration de variables de contrôle (concurrence, sentiment, promotions)
- Déploiement d'un dashboard analytique interactif permettant l'analyse du ROI par canal et par géographie, avec diagnostics de convergence bayésienne (R-hat, trace plots)
- Réimplémentation de l'architecture Meridian avec PyMC pour une maîtrise approfondie des mécanismes bayésiens sous-jacents

Stack : Python, PyMC, Prefect, Streamlit, GitHub Actions

Projet 4 - Prédiction de Consommation d'Énergie - Zone Commerciale | Académique

- Étude prédictive sur la consommation énergétique d'un centre commercial, avec comparaison de modèles de séries temporelles (ARIMA, SARIMA) et deep learning (LSTM)
- Production de visualisations analytiques et de recommandations opérationnelles pour la réduction des coûts énergétiques

Stack : Python, SQL, Pandas, Statsmodels, TensorFlow, Keras, Scikit-Learn

Projet 5 - Prédiction des Retards de Vols | Académique

- Analyse exploratoire approfondie (EDA) sur un large dataset aérien, suivi d'un preprocessing complet (gestion des valeurs manquantes, encodage, normalisation)
- Implémentation et évaluation comparative de modèles de classification (Random Forest, KNN) avec métriques adaptées (précision, rappel, F1-score)

Stack : Python, SQL, Pandas, Scikit-Learn, Seaborn, Matplotlib